



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

ANEXO B

Identificación de regímenes de mercado
mediante análisis de noticias financieras y
técnicas de clustering aplicadas a series
temporales

Autor: Álvaro Fernández Gutiérrez

Director: Guillermo Mestre Marcos

Madrid, Enero 2026

Índice

1	Introducción	1
2	Trabajos Relacionados	2
3	Motivación y Objetivos	3
3.1	Motivación	3
3.2	Objetivos	3
3.3	Alineación con los Objetivos de Desarrollo Sostenible	4
4	Metodología de trabajo	5
4.1	Cronograma	5
5	Recursos	6
5.1	Software	6
5.2	Hardware	6
5.3	Set de datos	7
6	Bibliografía	8

1 Introducción

La identificación de regímenes de mercado constituye un problema relevante en el ámbito del análisis financiero, ya que los mercados no presentan un comportamiento homogéneo en el tiempo, sino que alternan entre distintos estados caracterizados por dinámicas diferenciadas de riesgo, volatilidad y retorno. Tradicionalmente, estos regímenes se han estudiado a partir de variables puramente cuantitativas, como precios, volatilidad histórica o indicadores técnicos, lo que limita la incorporación de información contextual externa.

En este contexto, las noticias financieras representan una fuente de información rica y complementaria, capaz de reflejar expectativas, percepciones y tensiones latentes en los mercados. No obstante, su carácter no estructurado dificulta su integración directa en modelos de análisis convencionales. El problema abordado en este proyecto se centra en cómo transformar grandes volúmenes de texto financiero en indicadores cuantificables que puedan ser utilizados para caracterizar el estado del mercado de forma acertada.

La solución propuesta se apoya en técnicas avanzadas de Procesamiento del Lenguaje Natural (NLP) aplicadas a bases de datos de noticias financieras, como FNSPID. Mediante el uso de modelos basados en arquitecturas BERT, incluyendo variantes especializadas en finanzas como FinBERT, se extrae información semántica relevante en forma de estimaciones de sentimiento y métricas agregadas. Estos indicadores textuales se combinarán posteriormente con variables de mercado tradicionales para construir representaciones que permitan modelar el comportamiento del mercado.

El objetivo principal de este anexo es explicar los fundamentos que sustentan la construcción de dichos indicadores y su integración en técnicas de clustering aplicadas a series temporales. La automatización de este proceso permite identificar regímenes de mercado de manera objetiva, reducir la dependencia de análisis manuales y facilitar el estudio del comportamiento de activos, sectores o carteras bajo distintos estados del mercado, contribuyendo así a una mejor evaluación de estrategias de inversión.

2 Trabajos Relacionados

La identificación de regímenes de mercado ha sido un tema recurrente en el ámbito de las finanzas, tradicionalmente abordado mediante modelos econométricos y técnicas basadas en series temporales, como modelos de cambio de régimen o métodos de clustering aplicados a retornos y volatilidad [3]. Estos enfoques permiten capturar dinámicas no estacionarias del mercado, aunque se apoyan exclusivamente en información cuantitativa derivada de precios y volúmenes, ignorando el papel de la información textual procedente de noticias financieras.

De forma paralela, diversos trabajos han estudiado la relación entre el sentimiento extraído de noticias financieras y el comportamiento de los mercados. En particular, se ha demostrado que el sentimiento mediático está estrechamente relacionado con episodios de alta volatilidad y con la propagación del riesgo entre activos y sectores, evidenciando que la información textual actúa como un canal relevante de transmisión de incertidumbre en los mercados financieros [1]. Estos estudios ponen de manifiesto que el análisis de noticias aporta información complementaria a las variables de mercado tradicionales.

Los recientes avances en Procesamiento del Lenguaje Natural (NLP), y en particular el uso de modelos basados en arquitecturas profundas como BERT y sus variantes especializadas para el dominio financiero (FinBERT), han permitido una extracción más precisa de sentimiento y contenido semántico a partir de grandes volúmenes de noticias financieras.

En esta línea, trabajos recientes han propuesto integrar información procedente de noticias financieras con modelos de identificación de regímenes de mercado. Destaca especialmente el trabajo de [4], que emplea modelos FinBERT y técnicas de clustering para series temporales con el objetivo de detectar y predecir cambios de régimen de mercado en distintos sectores. Sus resultados muestran que la incorporación de información textual mejora de forma significativa la capacidad predictiva frente a modelos basados únicamente en series temporales, lo que refuerza la hipótesis de que las noticias contienen señales relevantes sobre cambios estructurales del mercado.

No obstante, gran parte de la literatura existente se centra bien en la predicción directa de precios mediante modelos de aprendizaje profundo [2], bien en el análisis del sentimiento de forma aislada, o bien en la detección de regímenes usando exclusivamente variables cuantitativas. Son menos frecuentes los trabajos que proponen un marco integrado que combine indicadores de sentimiento derivados de noticias financieras, técnicas de NLP avanzadas y variables de mercado tradicionales para la segmentación temporal del mercado en regímenes interpretables, y que además evalúen el comportamiento de sectores o carteras en cada uno de dichos regímenes.

En este contexto, el presente trabajo se sitúa en el punto de intersección entre estas líneas de investigación, proponiendo un enfoque que integra análisis de noticias financieras mediante NLP, construcción de indicadores de sentimiento y variables de mercado para la identificación automática de regímenes de mercado mediante técnicas de clustering aplicadas a series temporales. Este enfoque permite no solo detectar estados del mercado, sino también analizar patrones sectoriales y evaluar el potencial impacto de estos regímenes en estrategias de inversión, contribuyendo así a cubrir el vacío existente en la literatura.

3 Motivación y Objetivos

3.1 Motivación

Los mercados financieros se caracterizan por presentar dinámicas complejas y no estacionarias, en las que los periodos de estabilidad suelen alternarse con episodios de elevada volatilidad e incertidumbre. La correcta identificación de estos estados o regímenes de mercado resulta fundamental tanto para el análisis económico como para la toma de decisiones en contextos de inversión, gestión del riesgo y supervisión financiera.

Tradicionalmente, la identificación de regímenes de mercado se ha abordado mediante modelos econométricos y técnicas basadas exclusivamente en variables cuantitativas, como retornos, volatilidad o volumen negociado. Si bien estos enfoques permiten capturar cambios estructurales en el comportamiento del mercado, tienden a ignorar el papel de la información textual procedente de noticias financieras, que refleja expectativas, percepciones y reacciones de los agentes económicos ante eventos relevantes.

Además, numerosos estudios han mostrado que el contenido y el sentimiento de las noticias financieras están estrechamente relacionados con episodios de alta volatilidad y con la propagación del riesgo entre activos y sectores. Sin embargo, gran parte de la literatura trata esta información de forma aislada o la emplea únicamente con fines predictivos a corto plazo, sin integrarla totalmente en el marco de análisis de regímenes de mercado.

En este contexto, resulta relevante explorar enfoques que combinen información textual extraída de noticias financieras, mediante técnicas avanzadas de Procesamiento del Lenguaje Natural (NLP), con variables tradicionales de mercado. Este enfoque integrado puede contribuir a una mejor comprensión de los estados del mercado, proporcionando una visión más completa de los cambios que afectan a los mercados financieros y poder anticiparse a ellos.

3.2 Objetivos

El objetivo principal de este Trabajo Fin de Grado es desarrollar un marco metodológico que permita identificar de forma automática regímenes de mercado a partir de la integración de información procedente de noticias financieras y variables cuantitativas de mercado, empleando técnicas de NLP y métodos de clustering aplicados a series temporales.

De forma complementaria, se plantean los siguientes objetivos secundarios:

- Analizar y procesar conjuntos de datos de noticias financieras mediante técnicas de NLP, incluyendo la extracción de sentimiento y la generación de representaciones semánticas agregadas en el tiempo.
- Combinar los indicadores derivados del análisis de noticias con variables de mercado tradicionales, como retornos, volatilidad histórica y volumen negociado, para segmentar el mercado en distintos regímenes mediante técnicas de clustering.

- Estudiar el comportamiento de sectores, factores o carteras representativas bajo los distintos regímenes identificados, evaluando la existencia de patrones consistentes y su posible utilidad en el análisis financiero y la inversión.

—

3.3 Alineación con los Objetivos de Desarrollo Sostenible

El presente proyecto contribuye de forma indirecta a varios Objetivos de Desarrollo Sostenible (ODS) definidos por las Naciones Unidas, en particular:

- **ODS 8: Trabajo decente y crecimiento económico.** La mejora en la comprensión del funcionamiento de los mercados financieros y de los episodios de inestabilidad contribuye a un sistema financiero más eficiente y resiliente, favoreciendo un crecimiento económico sostenible.
- **ODS 9: Industria, innovación e infraestructura.** El uso de técnicas avanzadas de inteligencia artificial y procesamiento del lenguaje natural aplicadas al análisis financiero promueve la innovación tecnológica y el desarrollo de herramientas analíticas avanzadas.
- **ODS 12: Producción y consumo responsables.** Una mejor identificación de regímenes de mercado y de periodos de riesgo puede contribuir a una gestión más responsable del riesgo financiero, apoyando decisiones de inversión más informadas y sostenibles.

4 Metodología de trabajo

El desarrollo del presente Trabajo Fin de Grado se organiza en una serie de fases secuenciales que permiten cumplir de forma ordenada los objetivos planteados. La metodología combina la revisión del estado del arte, el tratamiento de datos, la aplicación de técnicas de Procesamiento del Lenguaje Natural (NLP) y el análisis cuantitativo de series temporales, finalizando con la evaluación y documentación de los resultados.

En una primera fase se realiza la revisión bibliográfica y la definición del problema, con el fin de delimitar el alcance del proyecto y seleccionar las técnicas más adecuadas. Posteriormente, se lleva a cabo la recopilación, limpieza y análisis exploratorio de los datos de noticias financieras y de variables de mercado. A continuación, se aplican técnicas de NLP para la extracción de indicadores de sentimiento y representaciones semánticas, que se integran con variables cuantitativas de mercado para la identificación de regímenes mediante técnicas de clustering aplicadas a series temporales.

Finalmente, se analizan los regímenes identificados desde un punto de vista económico y financiero, se evalúa la robustez de los resultados obtenidos y se procede a la redacción de la memoria final del trabajo.

Las tareas que estructuran el desarrollo del proyecto son las siguientes:

1. Revisión bibliográfica y definición del problema.
2. Recopilación y análisis exploratorio de datos.
3. Procesamiento de noticias y extracción de sentimiento mediante NLP.
4. Integración de variables de mercado y clustering de regímenes.
5. Análisis económico y evaluación de resultados.
6. Redacción de la memoria y revisión final.

4.1 Cronograma

Table 1: Cronograma de trabajo del TFG

	2025				2026				
	Sep	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May
Tarea 1	1	1							
Tarea 2		2	2						
Tarea 3			3	3	3				
Tarea 4					4	4	4		
Tarea 5						5	5	5	
Tarea 6								6	6

5 Recursos

En esta sección se describen los recursos necesarios para el desarrollo del Trabajo Fin de Grado, incluyendo el software, el hardware y los conjuntos de datos empleados a lo largo del proyecto.

5.1 Software

El desarrollo del proyecto se realiza principalmente en el lenguaje de programación **Python**, debido a su amplio uso en el ámbito del análisis de datos, el aprendizaje automático y el Procesamiento del Lenguaje Natural. Para la implementación de los distintos módulos del proyecto se emplean las siguientes herramientas y librerías especializadas:

- **PyTorch**. Framework de aprendizaje profundo utilizado para la carga y uso de modelos basados en arquitecturas BERT y FinBERT, así como para la gestión de embeddings textuales.
- **Transformers (Hugging Face)**. Librería estándar para el uso de modelos de lenguaje preentrenados, empleada para la extracción de sentimiento y representaciones semánticas a partir de noticias financieras.
- **scikit-learn**. Utilizada para la implementación de técnicas de clustering y análisis exploratorio, así como para la evaluación de los resultados obtenidos.
- **Jupyter Notebook / JupyterLab**. Entorno interactivo empleado para el análisis exploratorio de datos, experimentación y visualización de resultados.
- **Git**. Sistema de control de versiones utilizado para la gestión del código y el seguimiento del desarrollo del proyecto.

Todas las herramientas utilizadas son de código abierto y cuentan con licencias que permiten su uso con fines académicos.

5.2 Hardware

El desarrollo y las pruebas del proyecto se llevan a cabo principalmente en un ordenador personal. Las tareas de mayor carga computacional, asociadas al procesamiento de texto y al uso de modelos de lenguaje preentrenados, pueden beneficiarse del uso de aceleración mediante GPU. A continuación se describen los recursos hardware considerados:

- **Ordenador personal**.
- **GPU**. Tarjeta gráfica compatible con CUDA, para acelerar la inferencia de modelos basados en BERT/FinBERT cuando sea necesario.

- **Almacenamiento.** Unidad de almacenamiento con capacidad suficiente (del orden de decenas de GB) para albergar los conjuntos de datos de noticias financieras y los datos de mercado empleados en el proyecto.

—

5.3 Set de datos

Para el desarrollo del proyecto se emplean conjuntos de datos de noticias financieras y datos de mercado, que permiten integrar información textual y cuantitativa en el análisis de regímenes de mercado:

- **FNSPID (Financial News and Stock Price Integration Dataset).** Conjunto de datos que contiene noticias financieras asociadas a empresas cotizadas, junto con información temporal que permite su alineación con variables de mercado. El dataset incluye cientos de miles de titulares de noticias y textos financieros, y ha sido previamente utilizado en trabajos de análisis de sentimiento y NLP aplicado a finanzas [5].
- **Datos de mercado.** Series temporales de precios, retornos, volatilidad histórica y volumen negociado, obtenidas a partir de fuentes públicas o bases de datos financieras estándar. Estos datos se emplean para caracterizar el comportamiento del mercado y para la identificación de regímenes mediante técnicas de clustering.

6 Bibliografía

- [1] Hooman Abdollahi, Sturla L. Fjesme, and Espen Sirnes. “Measuring market volatility connectedness to media sentiment”. In: *North American Journal of Economics and Finance* 71 (2024), p. 102091.
- [2] Md Masum Billah et al. “Stock price prediction: comparison of different moving average techniques using deep learning model”. In: *Neural Computing and Applications* (2024).
- [3] James D. Hamilton. “A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle”. In: *Econometrica* 57.2 (1989), pp. 357–384.
- [4] Timur Mudarisov et al. “Cross-Sector Market Regime Forecasting with LLM-Augmented News Analysis”. In: *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF '24)*. 2024.
- [5] Zhang Zihan et al. “FNSPID: A Financial News and Stock Price Integration Dataset”. In: *arXiv preprint arXiv:2101.00000* (2021).